Cod	Nume indicator	Descriere
nama_10r_2gdp - PIB	Gross domestic product (GDP) at current market prices by NUTS 2 region	Indicatorul exprima valoarea PIB ului pe locuitor, calculat la preturile curente de piata , raportat la media Uniunii Europene .
tgs00010 - Rata_somaj	Unemployment rate by NUTS 2 region by all ISCED 2011 levels	Indicatorul exprima proportia persoanelor aflate in somaj din totalul populatiei active.
ilc_mdes05_r - Arrears	Arrears (mortgage or rent, utility bills or hire purchase) by NUTS 2 region	Persoanele care nu au putut plati la timp chiria, ipoteca, utilitatile sau rate la bunuri.
ilc_peps11n - Risc_saracie	Persons at risk of poverty or social exclusion by NUTS 2 region	Persoanele care se afla in risc de saracire sau excluziune sociala.
tgs00099 - Migratia	Population change by NUTS 2 region - Crude rates of net migration plus adjustment	Migratia neta se refera la diferenta dintre imigranti si emigrant, iar ajustarea statistica la alte variatii ale populatiei care nu pot fi explicate (erori de raportare, actualizare de recensamant).
tgs00099 - Natural_Change	Population change by NUTS 2 region - Crude rates of natural change plus adjustment	Indicatorul exprima diferenta dintre natalitate si mortalitate, iar ajustarea statistica la alte variatii ale populatiei care nu pot fi explicate (erori de raportare, actualizare de recensamant).
tran_r_elvehst - Masini_electrice	Stock of electric vehicles by category and NUTS 2 region	Ponderea masinilor electrice in totalul masinilor inregistrate.
tour_occ_arn2 - Turism	Arrivals at tourist accommodation establishments by NUTS 2 region	Evolutia numarului de sosiri ale turistilor straini in unitatile de cazare.
edat_lfse_16 - Abandon_scolar	Early leavers from education and training by NUTS 2 region	Abandonul scolar pentru tinerii cuprinsi intre varsta de 18 si 24 ani.
tgs00109 - Finalizare_studii_tertiare	Persons aged 25-64 with tertiary educational attainment level by sex and NUTS 2 region	Acest indicator atrata procentul persoanelor cu varsta intre 25-64 ani care au finalizat studii tertiare (facultate, master doctorat).
edat_lfse_33 - Angajare_studii_finale	Employment rates of young persons not in education and training by educational attainment level, years since completion of highest level of education and NUTS 2 region	Acest indicator masoara procentul tinerilor careau finalizat studiiletertiare si care sunt angajati.

hrst_st_rcat - HRST	Human resources in science and technology (HRST) by category and NUTS 2 region	Acest indicator masoara doar persoanele angajate in domenii stiintifice si tehnologice si arata potentialul in domaniul inovatiei si cercetarii.
ilc_mdes01_r – inability_warm_house	Inability to keep home adequately warm by NUTS 2 region	Indicatorul masoara proportia persoanelor aflate in somaj pe termen lung (de 12 luni sau mai mult), fiind calculat ca procent din rata somajului.
ilc_mdes03_r n - unaffordable_meal	Inability to afford a meal with meat, chicken, fish (or vegetarian equivalent) every second day by NUTS 2 region	Acest indicator arata procentul persoanelor care nu isi pot permite o masa compusa din carne sau peste o data la doua zile.
lfst_r_lfu2ltu – long_term_unemployment	Persons in long-term unemployment (12 months or more) by educational attainment level and NUTS 2 region	Acest indicator arata procentul persoanelor care declara ca nu isi pot mentine locuinta suficient de calda, din cauza neajunsurilor financiare.

Tema este: “Saracia si impactul sau asupra calitatii vietii”

Scopul analizei este de a examina relatia dintre saracie si calitatea vietii la nivel regional (NUTS 2) in Uniunea Europeana, utilizand indicatori socio-economici, demografici si educationali pentru anul 2023.

Toti indicatorii inclusi in baza de date se refera la anul 2023 si la nivelul geographic NUTS 2. Unitatile de masura sunt exprimate in procente pentru a permite comparabilitatea intre regiuni, iar sursa datelor este Eurostat.

```
> summary(acp)
Importance of components:
                          Comp.1    Comp.2     Comp.3     Comp.4     Comp.5     Comp.6     Comp.7
Standard deviation     2.3967401 1.5146759 1.21114580 1.12312544 1.04548513 0.94009375 0.70499969
Proportion of Variance 0.3829576 0.1529495 0.09779161 0.08409405 0.07286928 0.05891842 0.03313497
Cumulative Proportion  0.3829576 0.5359071 0.63369870 0.71779275 0.79066203 0.84958045 0.88271542
                           Comp.8     Comp.9   Comp.10    Comp.11   Comp.12    Comp.13    Comp.14
Standard deviation     0.63604284 0.60799816 0.5380757 0.46166239 0.4188251 0.39955677 0.30131761
Proportion of Variance 0.02697003 0.02464412 0.0193017 0.01420881 0.0116943 0.01064304 0.00605282
Cumulative Proportion  0.90968545 0.93432957 0.9536313 0.96784007 0.9795344 0.99017741 0.99623023
                           Comp.15
Standard deviation     0.237795065
Proportion of Variance 0.003769766
Cumulative Proportion  1.000000000
```

Proportion of variance -> Prima componenta sintetizeaza aproximativ 38,3% din cantitatea initiala de informatie, cea de-a doua componenta explica aproximativ 15,3%, iar cea de-a treia, 9,7%

Cumulative Proportion -> Primele 2 comp principale explica (cumulat, impreuna) aproximativ 53,6% din informatia initiala

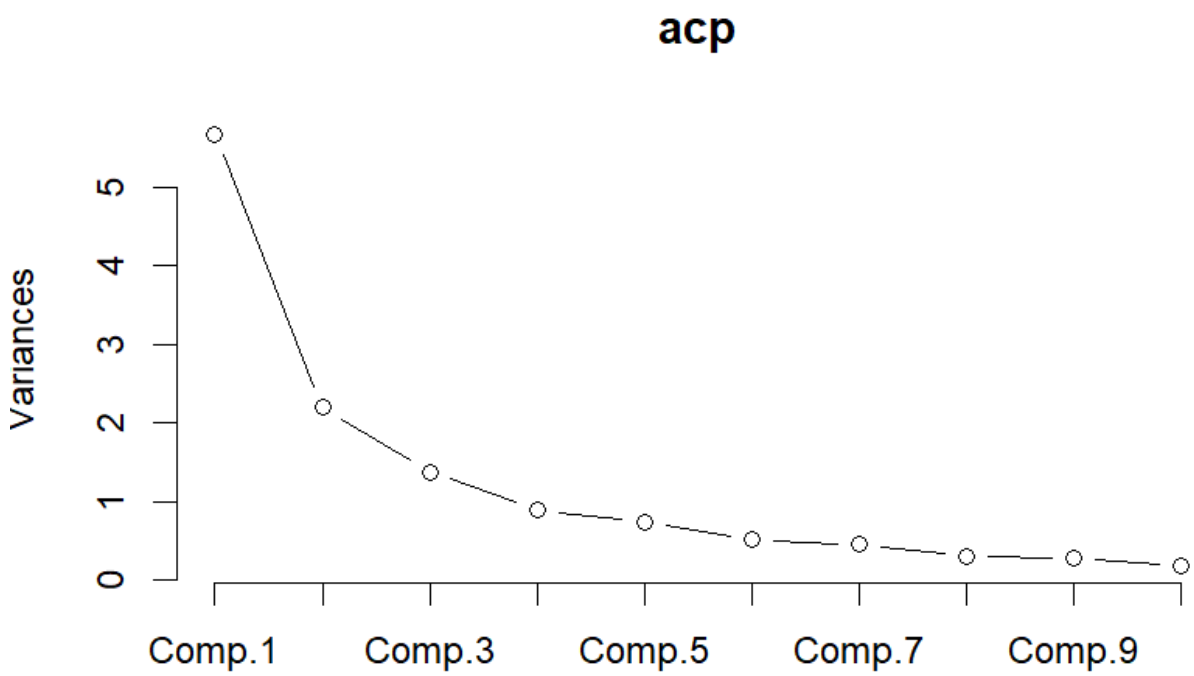


```
> acp$sdev^2
    Comp.1     Comp.2     Comp.3     Comp.4     Comp.5     Comp.6     Comp.7
5.68005655 2.19823878 1.38335218 0.90116960 0.74244140 0.52756390 0.45784974
    Comp.8     Comp.9    Comp.10    Comp.11    Comp.12    Comp.13
0.31232477 0.27971527 0.19603864 0.17289433 0.09142834 0.05692649
```

Pe baza scree plot ului si a criteriului lui Kaiser am decis sa aleg 4 componente, dupa a treia componenta, varianta incepe sa se stabilizeze treptat si sa fie <1 (criteriul lui Kaiser spune sa iau componentele care au varianta >1), insa, am decis sa las si componenta 4 deoarece am observant ca este puternic corelata cu variabila Arrears.

```
                              Comp.1      Comp.2      Comp.3      Comp.4
PIB                        0.7452528  0.43477752  0.04542774  0.09378717
Rata_somaj                -0.6512515  0.63414619 -0.22882521  0.15393655
Arrears                   -0.5116834  0.27325958 -0.08756349 -0.72158184
Risc_saracie              -0.7577274  0.46904624  0.26746300  0.05135242
Natural_Change             0.6131794  0.54714053  0.15715083  0.05268225
Masini_electrice           0.6830973  0.40076687  0.31511597  0.02084995
Abandon_scolar            -0.5031557  0.11897715  0.70240695  0.28393203
Finalizare_studii_tertiare 0.6372401  0.60617527 -0.17137917 -0.21295830
Angajare_studii_finale     0.6266994 -0.31505453  0.32936371 -0.37607278
HRST                       0.8423655  0.23735199  0.11544894 -0.02550517
inability_warm_house      -0.6853845  0.54877329 -0.01813600 -0.08729639
unaffordable_meal         -0.5536751 -0.10623357  0.64928224 -0.25715960
long_term_unemployment    -0.6957472  0.05269579 -0.24347003  0.01865325
```

Prima componenta principala se coreleaza puternic cu HRST (persoanele angajate in domenii stiintifice si tehnologice si arata potentialul in domaniul inovatiei si cercetarii.), PIB si Risc_saracie = **Prosperitate si potential uman**

A doua componenta principala se coreleaaza puternic cu Rata_somaj si Finalizare_studii_tertiare = **Nivel educational si ocupare**

A treia componenta se coreleaza puternic cu Abandon_scolar si unaffordable_meal (procentul persoanelor care nu isi pot permite o masa compusa din carne sau peste o data la doua zile.) = **Privare sociala**

A patra componenta se coreleaza puternicc cu Arrears (Persoanele care nu au putut plati la timp chiria, ipoteca, utilitatile sau rate la bunuri.) = **Capacitate de plata**

Reprezentați regiunile analizate astfel încât să surprindeți valorile înregistrate pentru primele 4 componente principale. Folosiți ggplot().

axe = dim 1, dim 2; dim 3 = col; dim 4 = size

```
scoruri_df<-as.data.frame(acp2$ind$coord)

windows()

ggplot(scoruri_df, aes(x=scoruri_df$Dim.1,y=scoruri_df$Dim.2))+

  geom_point(aes(size=scoruri_df$Dim.3, col=scoruri_df$Dim.4), alpha=0.5)+

  geom_text(label=rownames(scoruri_df),

          vjust=0,hjust=0,col="purple")
```

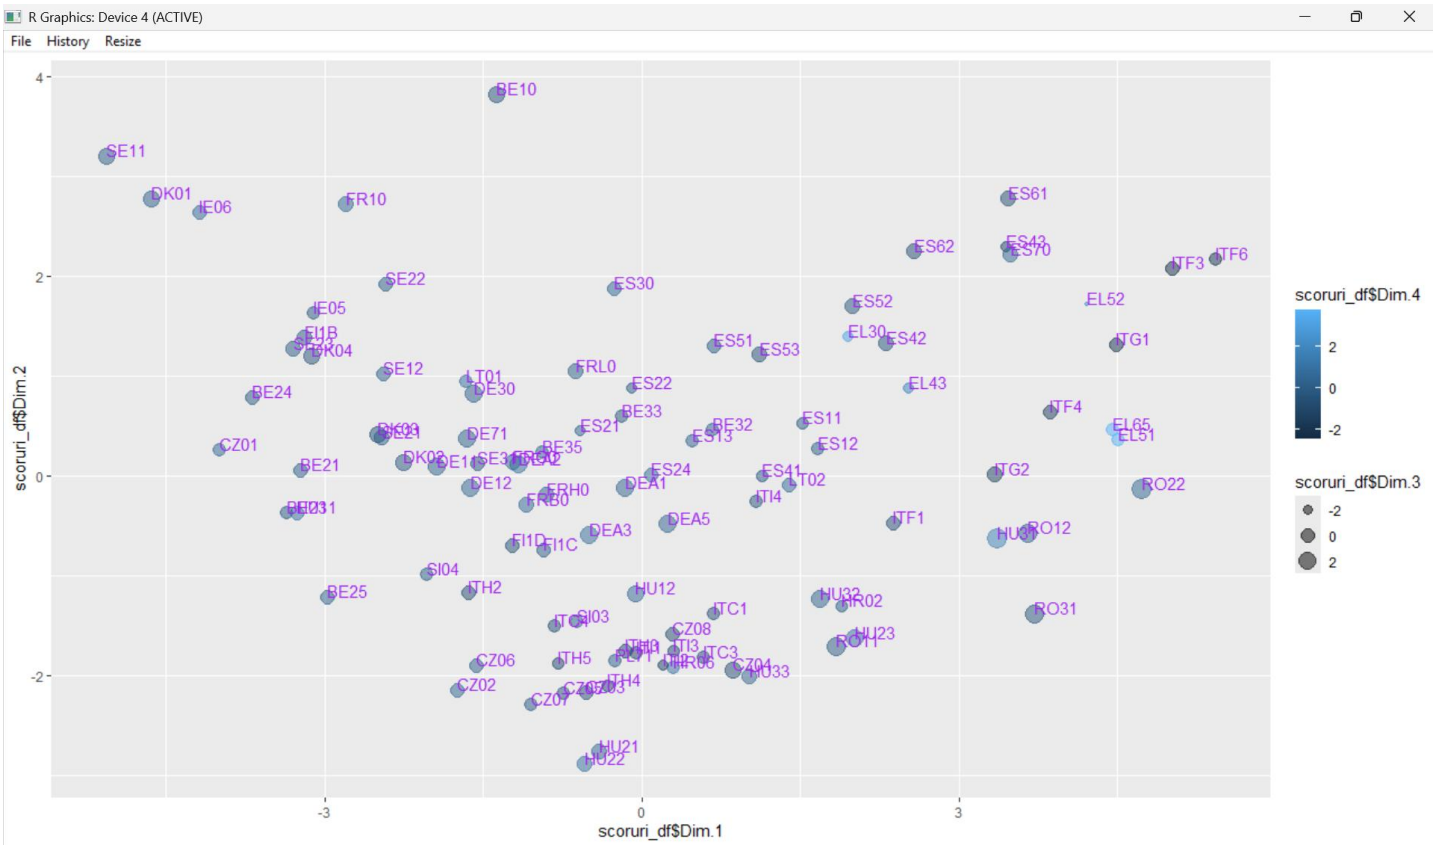

Dim 1 = Prosperitate si potential uman

Dim 2 = Nivel educational si ocupare

Dim 3 = Privare sociala

Dim 4 = Capacitate de plata

Regiunea BE10 are un nivel educational si ocupare mare, insa, nu se pozitioneaza prea bine pentru Dim 2 (scor negative, aproape de 0) care reprezinta Prosperitate si potential uman => PIB mic si nu dispun de oameni specializati in domenii tehnologice sau stiintifice.

Totodata, prezinta un nivel moderat pozitiv pentru privarea sociala (Dim 3) => indica riscuri de saracie medii, iar, pentru capacitatea de plata (Dim 4) se observa o valoare mica => probleme cu plata intretinerii locuintelor si datorii neprevazute.

Asadar, BE10 este o regiune cu o educatie buna, dar cu nivel modest de prosperitate, privare sociala moderata si prezinta datorii.

Outlieri: SE11, DK01, IE06, FR10, BE10 (regiuni subdezvoltate in cee ace proveste Prosperitatea si Resursele umane – PIB mai mic si putini oameni specializati in domenii stiintifice/tehnologice)

ES61, ITF3, ITF6 (regiuni mai dezvoltate, au valori mare pe aproape toate componentele)

```
> summary(ac)

Principal inertias (eigenvalues):

 dim    value      %   cum%   scree plot
 1      0.195883  95.3  95.3  ************************
 2      0.009716   4.7 100.0  *
        -------- -----
 Total: 0.205599 100.0


Rows:
        name   mass  qlt  inr    k=1 cor ctr    k=2 cor ctr
1 | Rsc_srch |  347 1000  390 | -474 969 397 |  -85  31 257 |
2 | Rsc_srcl |  327 1000  565 |  594 993 589 |  -50   7  84 |
3 | Rsc_srcm |  327 1000   45 |  -92 302  14 |  140 698 659 |

Columns:
           name   mass  qlt  inr    k=1 cor ctr    k=2 cor ctr
1 | Abndn_sclrh |  347 1000  547 | -568 993 570 |  -48   7  83 |
2 | Abndn_sclrl |  317 1000  402 |  503 968 409 |  -92  32 274 |
3 | Abndn_sclrm |  337 1000   51 |  111 400  21 |  136 600 642 |
>
```

#prima dimensiune preia aprox 95% din inertia initiala

#0.205599 = inertia totala din excel

#k= coordonatele in noul spatiu

#mass = frecv relative marginale ponderi, sunt la fel ca in excel

#qlt= valoarea reprezentarii punctului in grafic=> daca e aproape de 1 => e bine=> bine reprezentat => toate variabilele mele sunt bine reprezentate

#inr = contributia pe care fiecare linie/coloana o are la inertie

#la randuri, cea mai mare contrib o are Rsc_srclc = 0,565; iar pe coloane, Abndn_sclrh = 0,547

#Prima componenta preia 95.3% din inertie

#A doua componenta preia 4,7% din inertia totala

#Iar cumulat, se preia 100% din inertie

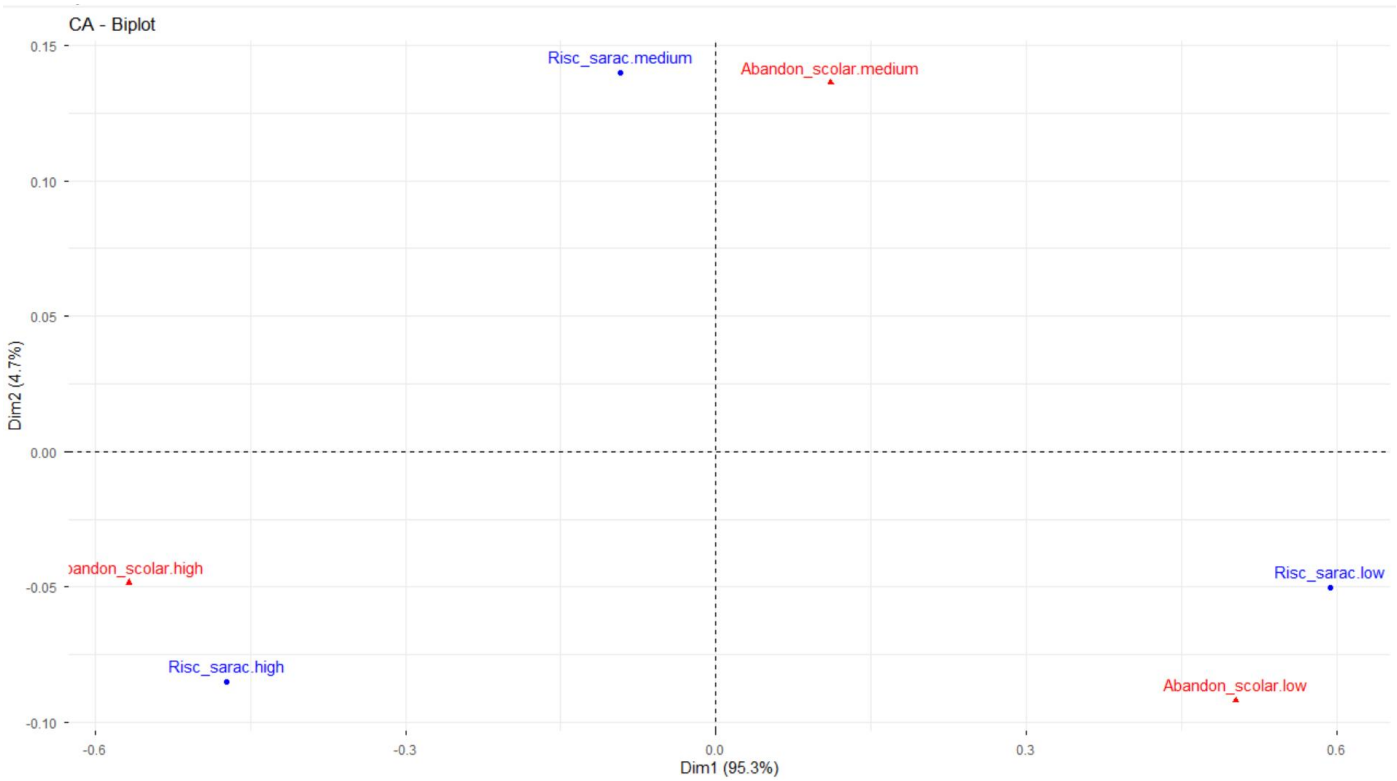

#putem vedea categoriile care contribuie cel mai mult la inertia totala.

#(categ care se afla in jurul originii nu se diferentiaza foarte mult de profilul mediu, cele care se distanteaza=> explica cea mai mare parte din inertie - in cazul meu categoriile se diferentiaza de profilul mediu deoarece nu se afla niciuna in jurul originii).

#Risc_sarac.low are o contributie mare pt Dim 1 si mica pt Dim 2.

#ASOCIERI dintre categoriile variabilei mele: Avem regiuni cu Risc al saraciei mic si cu abandon scolar, regiuni unde avem Risc_saracie mare si Abandon scolar mare, la fel si pentru Mediu

#Pe cele 2 axe vedem inertia explicata : Dim 1 (95,3)

Tabelul de contigenta

	A	B	C	D
1	FRECV OBSERVATE	Abandon_scolar.high	Abandon_scolar.low	Abandon_scolar.medium
2	Risc_sarac.high	20	6	9
3	Risc_sarac.low	3	18	12
4	Risc_sarac.medium	12	8	13
5		**35**	**32**	**34**
6		**0.346534653**	**0.316831683**	**0.336633663**
7				
8				
9	FRECV ASTEPTATE/TEORETICE	Abandon_scolar.high	Abandon_scolar.low	Abandon_scolar.medium
10	Risc_sarac.high	12.12871287	11.08910891	11.78217822
11	Risc_sarac.low	11.43564356	10.45544554	11.10891089
12	Risc_sarac.medium	11.43564356	10.45544554	11.10891089
13				

	MASS							
35	**0.34653465**	34% au un Risc al saraciei mare						
33	**0.32673267**							
33	**0.32673267**							
101								
		CONTRIBUTIA LA INERTIE	Abandon_scolar.high	Abandon_scolar.low	Abandon_scolar.medium	TOTAL	INERTIE	
		Risc_sarac.high	5.108304708	2.335537482	0.656968134	8.10081032	0.08020604	0.39010986
		Risc_sarac.low	6.222656551	5.444081908	0.071477736	11.7382162	0.11621996	0.56527603
		Risc_sarac.medium	0.027851357	0.576657666	0.321923369	0.92643239	0.0091726	0.04461411
		TOTAL	11.35881262	8.356277056	1.050369239	**20.7654589**	**0.2055986**	
		INERIE	0.112463491	0.082735416	0.010399695	0.2055986		
			0.547005133	0.402412347	0.05058252			

Testul KMO:

```
> library(psych)
> KMO(R)
Kaiser-Meyer-Olkin factor adequacy
Call: KMO(r = R)
Overall MSA =  0.74
MSA for each item =
                      PIB                 Rata_somaj                    Arrears               Risc_saracie
                     0.80                       0.61                       0.72                       0.75
            Natural_Change            Masini_electrice             Abandon_scolar Finalizare_studii_tertiare
                     0.88                       0.82                       0.68                       0.66
    Angajare_studii_finale                       HRST       inability_warm_house          unaffordable_meal
                     0.73                       0.81                       0.84                       0.55
    long_term_unemployment
                     0.84
```

Overall MSA = 0,74 > 0,5 => are sens sa aplic analiza factoriala pe datele mele

Testul Bartlett

```
> cortest.bartlett(R,n=101)
$chisq
[1] 953.4403

$p.value
[1] 1.133817e-150

$df
[1] 78
```

p_value = 1.133817e-150 => se respinge ip nula => avem cel putin un factor comun care sa explice variatia din variabilele mele

#Metoda verosimiliotatii maxime, fara rotirea axelor

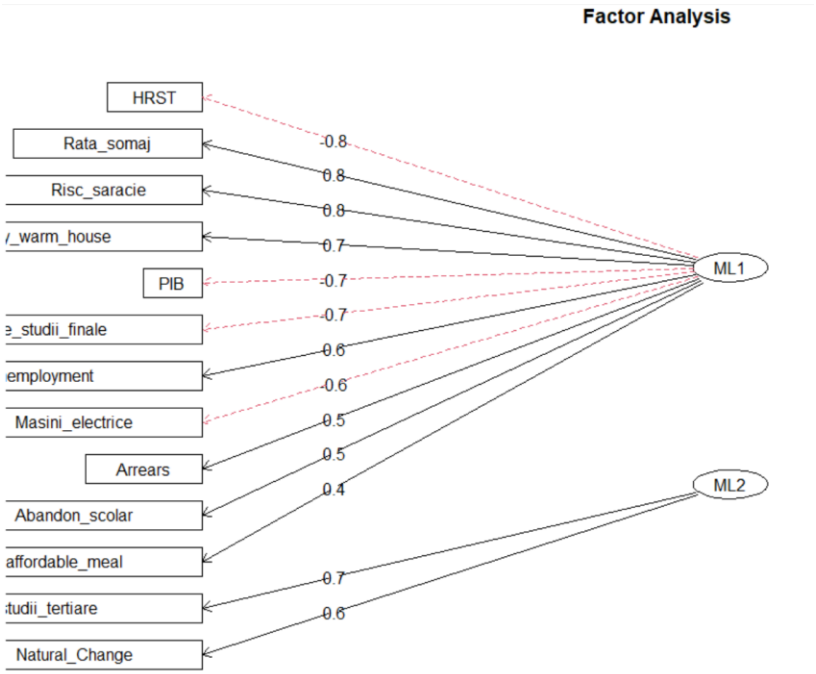

Primul factor latent imprima variatia variabilelor HRST, Rata_somaj, Risc_saracie, inability_warm_house, PIB, Angajare_studii_finale, Employment, Masini_electrice, Arrears, Unaffordable meal

Al doilea factor latent imprima variatia variabilelor Studii_tertiare si Natural_Change

```
> model1
Factor Analysis using method =  ml
Call: fa(r = R, nfactors = 2, n.obs = 101, rotate = "none", fm = "ml")
Standardized loadings (pattern matrix) based upon correlation matrix
                            ML1   ML2   h2   u2 com
PIB                       -0.66  0.50 0.69 0.31 1.9
Rata_somaj                 0.78  0.52 0.88 0.12 1.7
Arrears                    0.49  0.12 0.26 0.74 1.1
Risc_saracie               0.77  0.28 0.67 0.33 1.3
Natural_Change            -0.50  0.55 0.55 0.45 2.0
Masini_electrice          -0.60  0.44 0.55 0.45 1.8
Abandon_scolar             0.46 -0.03 0.21 0.79 1.0
Finalizare_studii_tertiare -0.50  0.70 0.75 0.25 1.8
Angajare_studii_finale    -0.66 -0.18 0.47 0.53 1.2
HRST                      -0.80  0.37 0.78 0.22 1.4
inability_warm_house       0.74  0.39 0.70 0.30 1.5
unaffordable_meal          0.40 -0.27 0.23 0.77 1.8
long_term_unemployment     0.64 -0.05 0.41 0.59 1.0

                       ML1  ML2
SS loadings           5.16 2.00
Proportion Var        0.40 0.15
Cumulative Var        0.40 0.55
Proportion Explained  0.72 0.28
```

In ML2 si Ml1 avem ponderile/intensitatiile (Q urile)

cor(F,X)=Q

H^2 = factorii comuni, comunalitatea

Var(Xi)comunalitate + specificitate

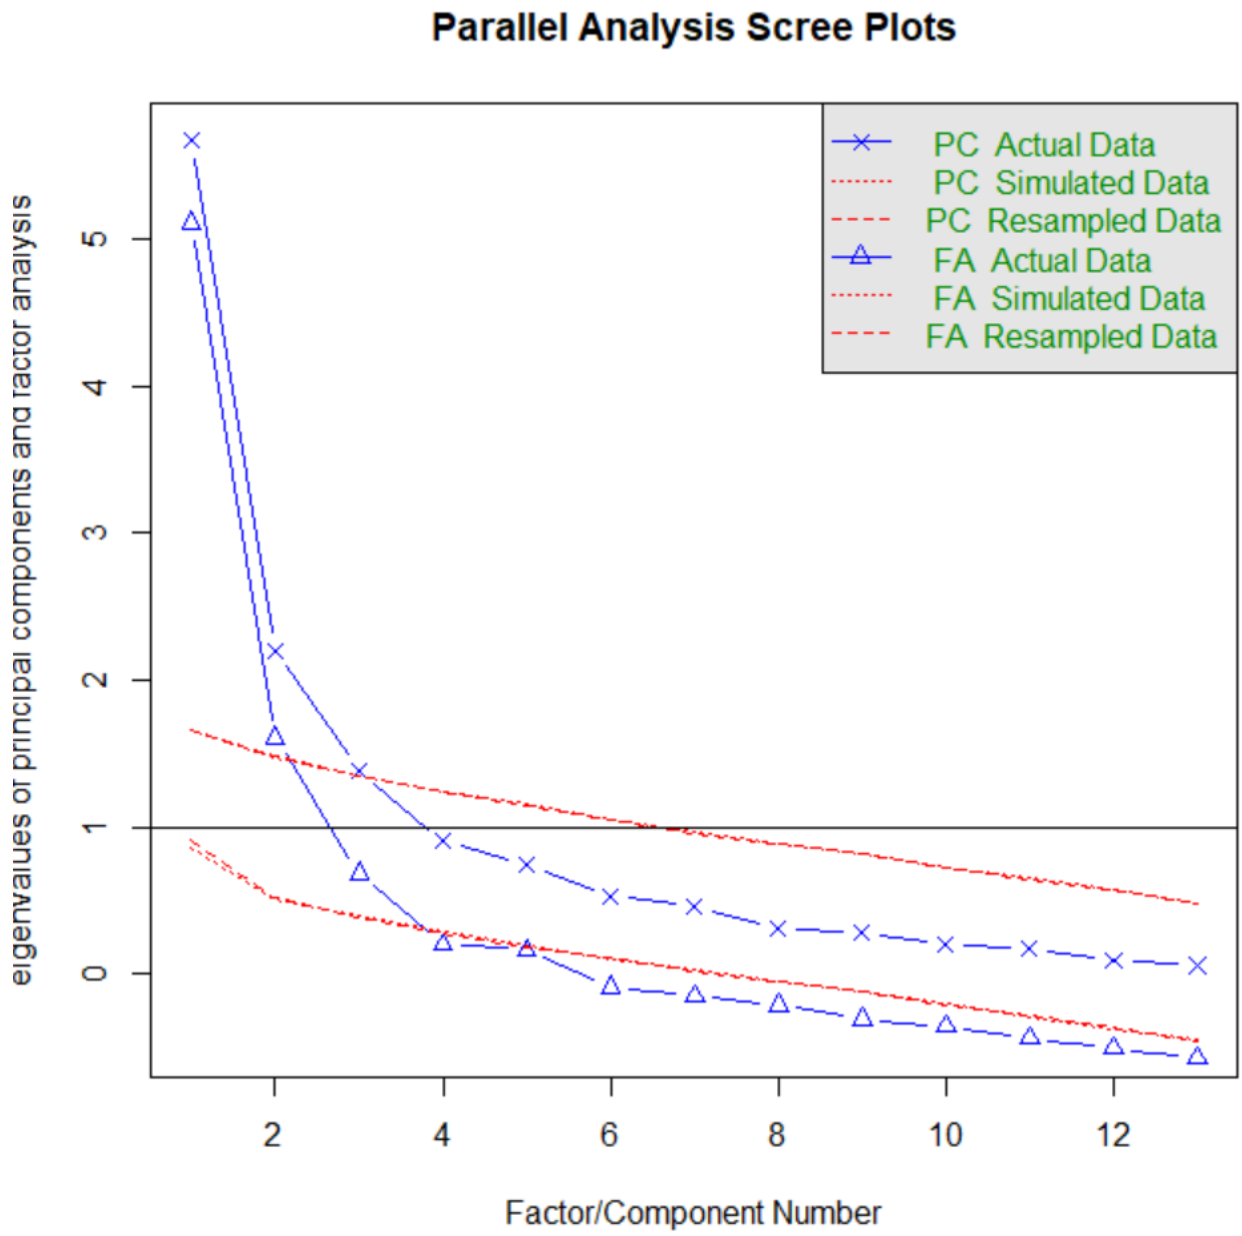

Dupa al trilea factor, valorile simulate sunt mai mari decat cele reale, asadar pastrez pentru analiza mead oar 3 factori.

```
> model2<-fa(R, nfactors=3, n.obs=101, rotate="none", fm="ml")
> fa.diagram(model2)
> model2
Factor Analysis using method =  ml
Call: fa(r = R, nfactors = 3, n.obs = 101, rotate = "none", fm = "ml")
Standardized loadings (pattern matrix) based upon correlation matrix
                            ML1   ML2   ML3   h2    u2 com
PIB                       -0.29  0.69  0.38 0.70 0.295 2.0
Rata_somaj                 1.00  0.04  0.00 1.00 0.005 1.0
Arrears                    0.43 -0.25  0.07 0.26 0.742 1.7
Risc_saracie               0.76 -0.40  0.38 0.87 0.125 2.0
Natural_Change            -0.13  0.61  0.42 0.56 0.441 1.9
Masini_electrice          -0.25  0.58  0.47 0.62 0.382 2.3
Abandon_scolar             0.34 -0.45  0.30 0.41 0.595 2.7
Finalizare_studii_tertiare -0.04  0.79  0.29 0.72 0.284 1.3
Angajare_studii_finale    -0.68  0.16  0.13 0.50 0.500 1.2
HRST                      -0.47  0.64  0.42 0.80 0.196 2.6
inability_warm_house       0.77 -0.20  0.14 0.65 0.349 1.2
unaffordable_meal          0.07 -0.79  0.49 0.87 0.134 1.7
long_term_unemployment     0.49 -0.41 -0.07 0.41 0.590 2.0
```

Met pa, fara rotirea axelor

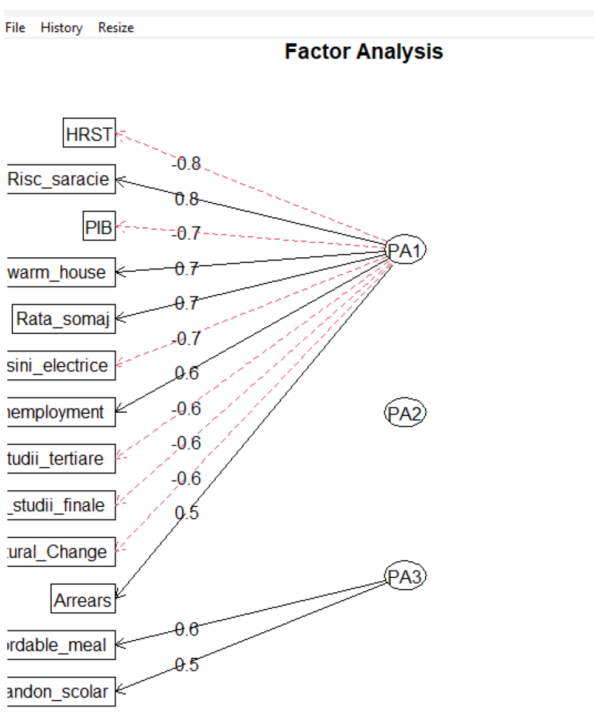

```
> fa.diagram(model3)
> model3
Factor Analysis using method =  pa
Call: fa(r = R, nfactors = 3, n.obs = 101, rotate = "none", fm = "pa")
Standardized loadings (pattern matrix) based upon correlation matrix
                            PA1   PA2   PA3   h2    u2 com
PIB                       -0.73  0.41  0.07 0.69 0.306 1.6
Rata_somaj                 0.67  0.65 -0.27 0.94 0.056 2.3
Arrears                    0.46  0.19 -0.04 0.25 0.752 1.3
Risc_saracie               0.77  0.47  0.30 0.90 0.100 2.0
Natural_Change            -0.58  0.48  0.14 0.59 0.412 2.0
Masini_electrice          -0.66  0.36  0.29 0.65 0.351 2.0
Abandon_scolar             0.48  0.10  0.51 0.49 0.509 2.1
Finalizare_studii_tertiare -0.63  0.58 -0.15 0.76 0.245 2.1
Angajare_studii_finale    -0.59 -0.25  0.24 0.47 0.534 1.7
HRST                      -0.83  0.24  0.14 0.77 0.232 1.2
inability_warm_house       0.67  0.50 -0.03 0.70 0.301 1.8
unaffordable_meal          0.53 -0.11  0.59 0.65 0.349 2.1
long_term_unemployment     0.65  0.04 -0.15 0.44 0.560 1.1

                       PA1  PA2  PA3
SS loadings           5.35 1.94 1.00
Proportion Var        0.41 0.15 0.08
Cumulative Var        0.41 0.56 0.64
Proportion Explained  0.65 0.23 0.12
Cumulative Proportion 0.65 0.88 1.00
```

Aleg sa folosesc mai departe in analiza mea metoda 3, deoarece are 3 factori si explica 64% din varianta totala, in timp ce modelul 1 cu 2 factori explica doar 55% din varianta. Desi modelul 2 explica tot 64%, variabila Rata_somaj are o comunalitate (h^2) de 1.

PA1 *(Dezvoltare si properitate)* este format din:

- PIB: -0.73 (relatie negativa)
- Risc_saracie: 0.77
- HRST: -0.83 (relatie negativa)
- inability_warm_house: 0.67
- long_term_unemployment: 0.65
- Masini_electrice: -0.66 (relatie negativa)
- Angajare_studii_finale: -0.59 (relatie negativa)
- Natural_Change: -0.58 (relatie negativa)
- Arrears: 0.46

PA2 *(Performanta educationala si integrarea pe piata muncii)* este format din:

- Rata_somaj: 0.65
- Finalizare_studii_tertiare: 0.58

PA3 *(Vulnerabilitate Sociala si Abandon)* este format din:

- Abandon_scolar: 0.51
- unaffordable_meal: 0.59

Clusterizare ierarhica

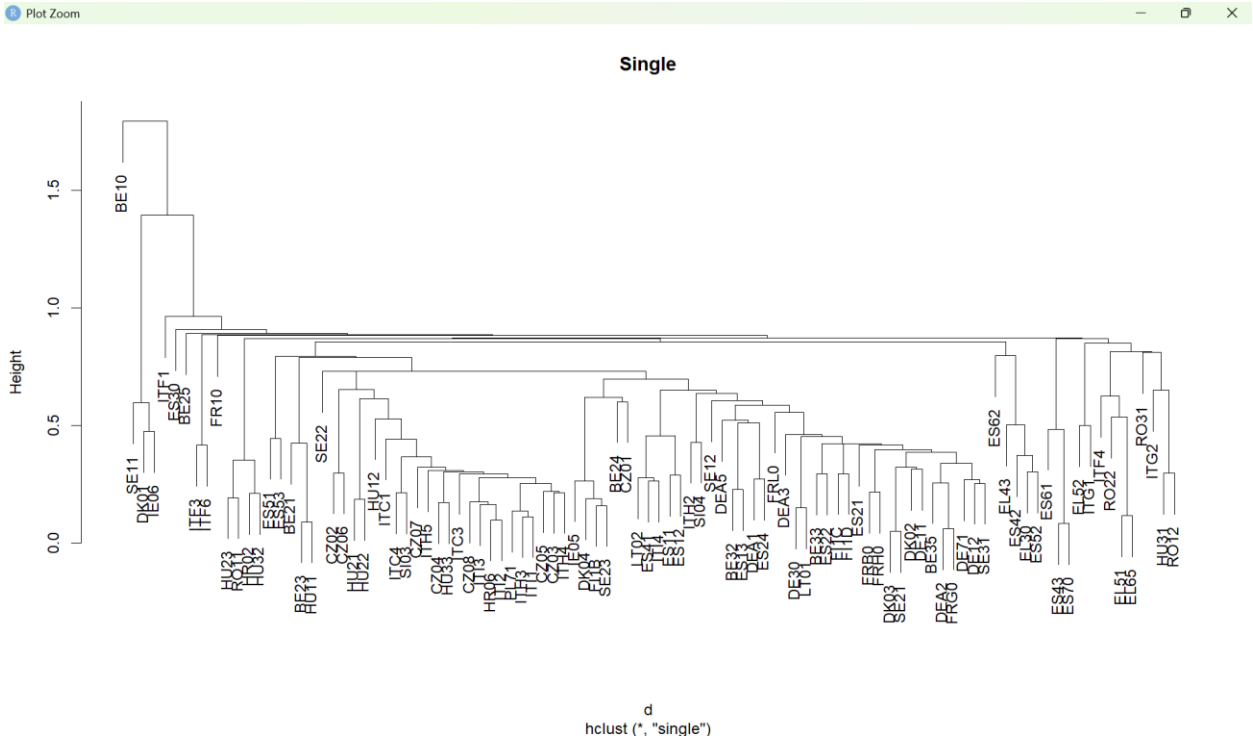

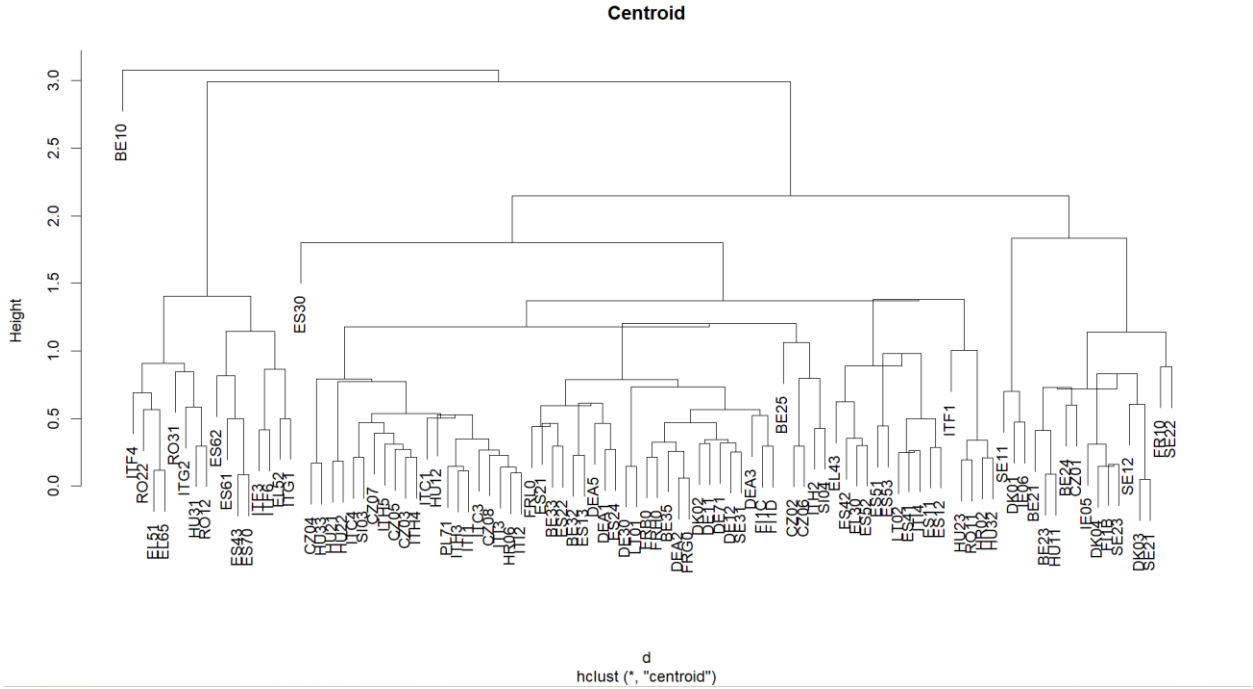

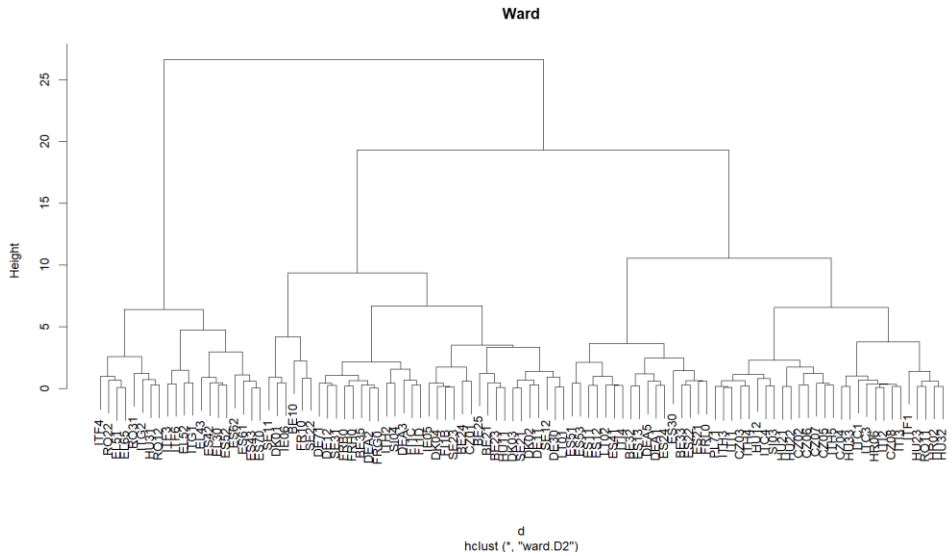

Am aplicat toate cele 3 metode: Singulara, Centroid si Ward, si se observa din dendograma mea ca Ward este cea mai buna metoda pentru aceasta analiza. Mai departe, am decis sa continui analiza cu 3 clustere.

```
> #Pastram o sulutie cu 3 clustere
> solutie3<-cutree(ierarhieW, k=3)
> table(solutie3)
solutie3
 1  2  3
36 45 20
```

Primul cluster contine 36 regiuni, al doilea 45 regiuni, iar al treilea cluster 20 regiuni.

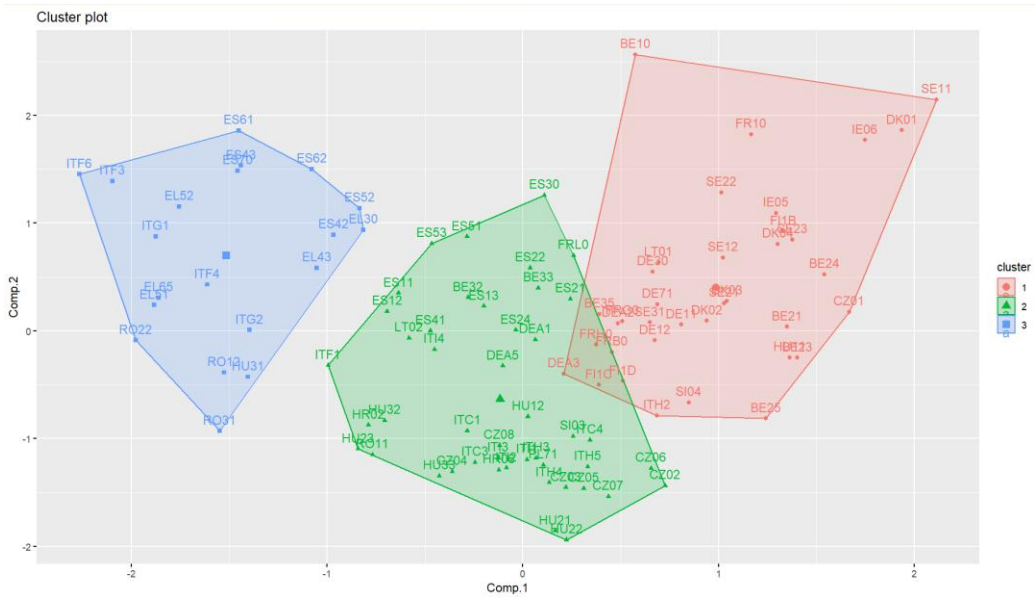

Se poate observa o suprapunere intre clusterul 1 si clusterul 2, ceea ce poate insemna ca unele regiuni nu au fost bine clasifiacte sau se afla la granita dintre aceste 2 clustere

```
> #media variabilelor
> aggregate(scoruri, list(solutie3), mean)
  Group.1     Comp.1     Comp.2
1       1  2.3628745  0.6014217
2       2 -0.2784346 -0.9437612
3       3 -3.6266962  1.0409036
```

In primul cluster, media primei componente (Prosperitate si potential uman) este de 2.36, iar pe componenta 2 (Nivel educational si ocupare) este de 0.6. Ceea ce inseamna ca regiunile aflate in acest cluster au un potential uman si de prosperitate foarte mare si un nivel de ducatie si ocupare mediu.

In al doilea cluster, regiunile au un nivel de prosperitate scazut (deoarece media este negative) si un nivel de educatie sim ai mic.

Al doilea cluster contine regiuni care au un nivel foarte mic pentru potentialul uman si properitate, insa, un nivel mare de educatie si ocupare.

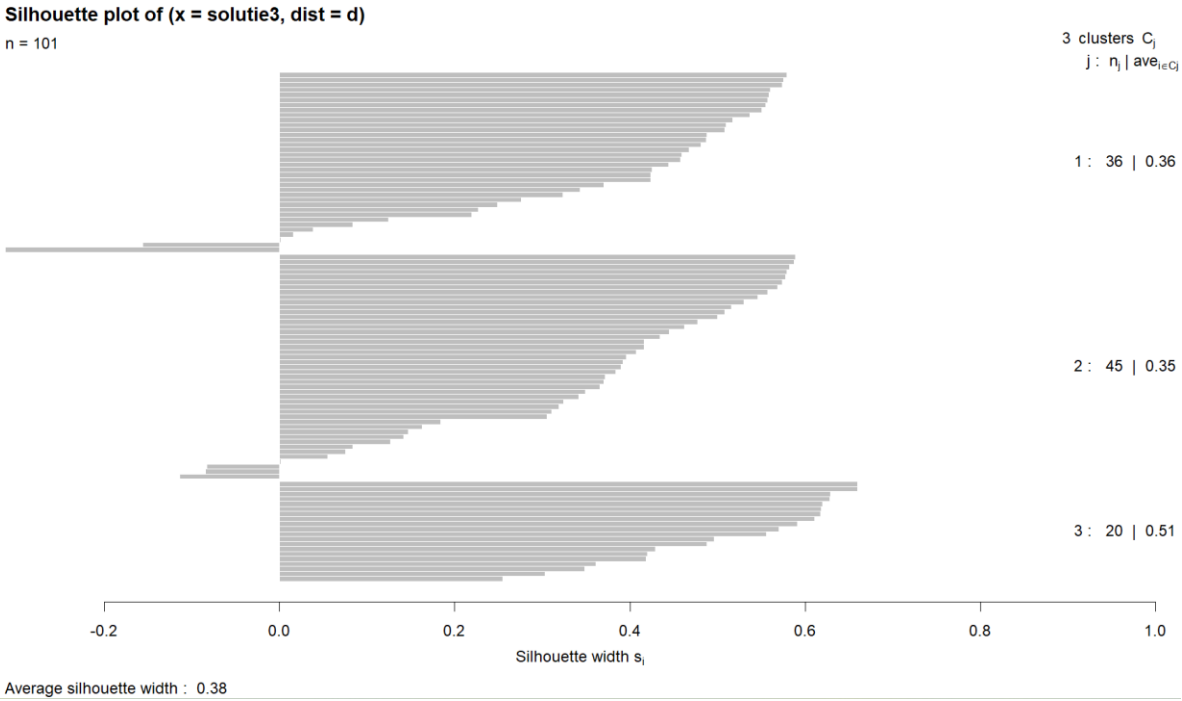

Din acest grafic se poate observa ca intr-adevar unele regiuni nu au fost bine clasificate, deoarece au o latime a siluetei negative. Asadar, regiunile prost clasificate sunt:

```
> row.names(date3)[s[, "sil_width"] < 0]
[1] "DEA3" "ES30" "FRL0" "ITF1" "FI1C"
>
```

Meoda kmeans:

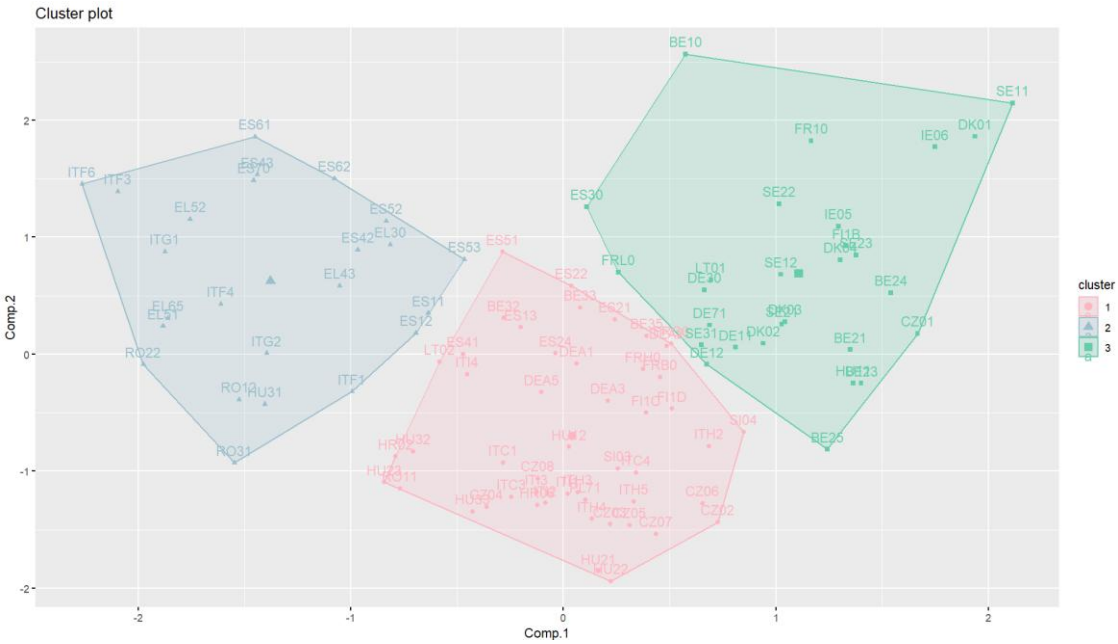

Clusterii sunt mult mai bine definiti prin aceasta metoda, nu mai exista suprapuneri

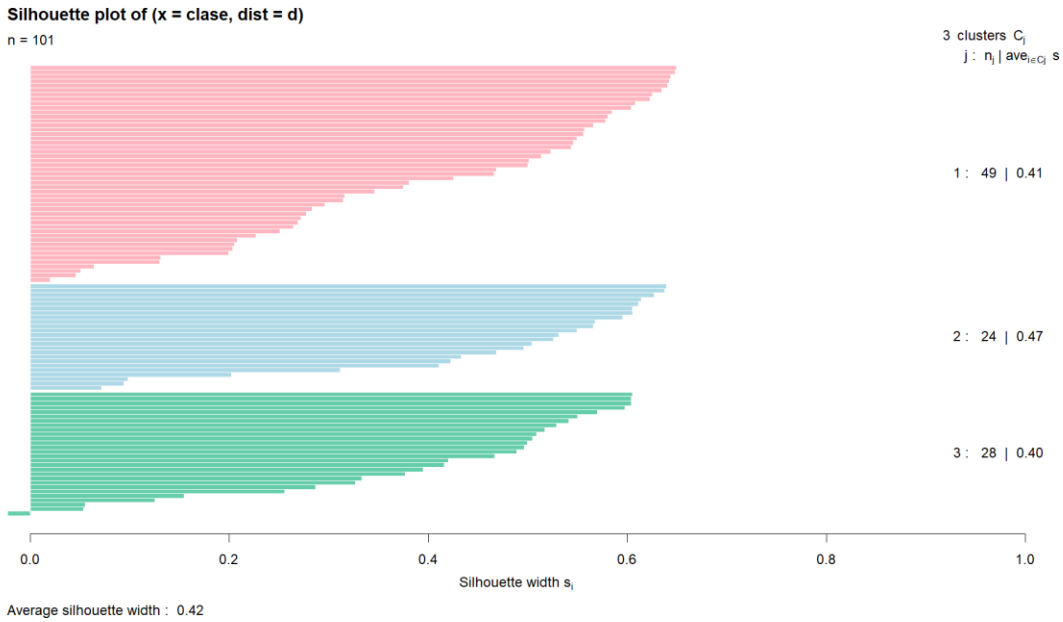

O singura regiune a ramas necorespunzator clasificata, si anume, FRL0, o regiune din Franta. Totodata, se observa ca lungimea medie a siluetei a crescut de la 0.38 (prin metoda clusterizarii ierarhice) la 0.42 (prin metoda kmeans). Asadar, cea mai buna solutie este redata de kmeans.

```
      Comp.1    Comp.2
1 -3.3005369  0.931084
2  2.6531255  1.027557
3  0.1005178 -1.043216
> table(clase)
clase
 1  2  3
24 28 49
```

Pentru metoda kmeans, primul cluster este format din 24 regiuni si are o medie foarte mica, negativa pentru potenialul uman si prosperitate, dar mare pentru educatie si ocupare.

Al doilea cluster este format din 28 regiuni si prezinta atat potentialul uman cat si educatia si ocuparea dezvoltate.

Iar al treilea cluster este format din 49 regiuni (este cel mai stabil, lucru care se observa de la inceput in analiza mea, prin ploturile mele). Regiunile sunt in curs de dezvoltare (deoarece nu au un potential uman si prosperiatte mare, nici negativa, se apropie de o zona neutra), insa nivelul educatiei este mic (media fiind de -1.04)